PENGGUNAAN *ARTIFICIAL NEURAL NETWORK* DENGAN *BACKPROPAGATION* UNTUK MEMPREDIKSI KUALITAS UDARA KHUSUS PM 2.5 DKI JAKARTA TAHUN 2023

Hana Nurul Wahidah[1], Keysha Jauzi Althaff[2], Muhammad Wildan Ramadhan[3], Rusdian Mulyana[4], Suliadi[5]

[1,2,3,4,5] Program Studi Statistika, Fakultas MIPA, Universitas Islam Bandung

e-mail: 10060122038@unisba.ac.id

Abstrak

Penelitian ini bertujuan untuk memprediksi konsentrasi polutan PM2.5 di DKI Jakarta pada tahun 2023 menggunakan metode *Artificial Neural Network* (ANN) dengan algoritma *backpropagation*. Data harian kualitas udara dari Stasiun Bundaran HI periode Mei–November 2023 digunakan sebagai dataset, dengan variabel input meliputi SO_2, CO, O_3, dan NO_2. Proses *preprocessing* dilakukan melalui pemeriksaan dan imputasi *missing value*, seleksi variabel, serta normalisasi menggunakan metode *min-max scaling*. Data dibagi menjadi data *training* (80%) dan *testing* (20%). Arsitektur jaringan terdiri dari 4 *neuron* input, dua *hidden layer* (masing-masing 5 dan 3 neuron), serta 1 *neuron output*, dengan fungsi aktivasi *logistic sigmoid* pada *hidden layer* dan fungsi linear pada *output layer*. Hasil evaluasi menunjukkan nilai MAPE sebesar 11,14%, MSE sebesar 124,46, serta koefisien determinasi (R^2) sebesar 0,2609 pada data *testing*. Meskipun akurasi model belum optimal, ANN mampu menangkap pola hubungan non-linear antara variabel pencemar udara dan konsentrasi PM2.5 secara cukup baik. Kendala utama penelitian meliputi keterbatasan jumlah data serta kompleksitas dalam pemilihan parameter optimal ANN. Model ini diharapkan dapat menjadi dasar pengembangan sistem prediksi kualitas udara yang lebih akurat di masa mendatang.

Kata Kunci: *Artificial Neural Network*; DKI Jakarta; Kualitas Udara PM 2.5; Prediksi

Abstract

This study aims to predict PM2.5 concentrations in DKI Jakarta during 2023 using an Artificial Neural Network (ANN) with the Backpropagation algorithm. Daily air quality data from the Bundaran HI monitoring station, covering the period from May to November 2023, were used as the dataset. The input variables included SO_2, CO, O_3, and NO_2. The preprocessing stage consisted of handling missing values through mean imputation, selecting relevant variables, and applying min–max normalization. The dataset was then divided into training data (80%) and testing data (20%). The ANN architecture consisted of four input neurons, two hidden layers with five and three neurons respectively, and one output neuron, employing the logistic sigmoid activation function in the hidden layers and a linear function in the output layer. Evaluation results show a MAPE of 11.14%, MSE of 124.46, and an R^2 value of 0.2609 on the testing data. Although the model has not achieved optimal accuracy, it is capable of capturing non-linear relationships between air pollutant variables and PM2.5 concentrations reasonably well. The main challenges encountered include limited data availability and the complexity of determining optimal ANN parameters. This model is expected to serve as a foundation for developing more accurate air quality prediction systems in the future.

Keywords: *Artificial Neural Network; DKI Jakarta; PM 2.5 Air Quality; Prediction*

1. PENDAHULUAN

Kualitas udara merupakan salah satu isu lingkungan yang krusial di wilayah perkotaan, terutama di daerah dengan tingkat aktivitas transportasi dan industri yang tinggi. DKI Jakarta sebagai pusat pemerintahan dan kegiatan ekonomi nasional menghadapi permasalahan pencemaran udara yang meningkat dari tahun ke tahun. Salah satu polutan yang paling berbahaya adalah PM2.5, yaitu partikulat halus berukuran kurang dari 2,5 mikrometer yang dapat masuk hingga ke saluran pernapasan bagian dalam. Berdasarkan laporan Dinas Lingkungan Hidup Provinsi DKI Jakarta[1], rata-rata konsentrasi PM2.5 di wilayah ini mencapai 39,2 $\mu g/m^3$, jauh melampaui ambang batas aman WHO sebesar 5 $\mu g/m^3$ [2]. Kondisi ini menimbulkan dampak serius bagi kesehatan masyarakat dan menurunkan kualitas hidup penduduk [3].

Tingginya paparan PM2.5 tersebut memunculkan kebutuhan akan sistem prediksi yang mampu memberikan gambaran konsentrasi polutan secara lebih akurat dan responsif. Pergerakan PM2.5 dipengaruhi oleh berbagai faktor seperti kepadatan lalu lintas, emisi industri, hingga kondisi cuaca harian. Kompleksitas hubungan antar variabel tersebut membuat pendekatan analisis linier tradisional kurang memadai untuk menggambarkan dinamika polutan yang bersifat *non-linear*.

Untuk menjawab kebutuhan tersebut, pendekatan berbasis *Artificial Neural Network* (ANN) dengan algoritma *backpropagation* menjadi salah satu metode yang relevan. ANN mampu mempelajari pola-pola kompleks dalam data runtun waktu, beradaptasi terhadap variasi data, serta menekan tingkat kesalahan prediksi melalui proses pelatihan berulang. Dengan kemampuan generalisasi yang baik, metode ini berpotensi memberikan prediksi kualitas udara yang lebih stabil, khususnya untuk parameter PM2.5.

Sejumlah penelitian sebelumnya juga telah memperkuat efektivitas metode ini dalam konteks kualitas udara. Model ANN terbukti mampu memprediksi parameter polutan seperti PM10, SO_2, CO, O_3, dan PM2.5 dengan tingkat kesalahan yang rendah [4]. Pengembangan ANN berbasis NARX juga ditemukan dapat meningkatkan akurasi prediksi kualitas udara dalam ruangan [5]. Selain itu, pemodelan kadar ozon menggunakan ANN di Kota Mataram menunjukkan tingkat akurasi yang tinggi dengan koefisien determinasi mencapai 95,67% [6]. Meskipun demikian, performa ANN tetap dipengaruhi oleh pemilihan parameter jaringan, jumlah data, serta faktor eksternal yang memerlukan proses optimasi lebih lanjut.

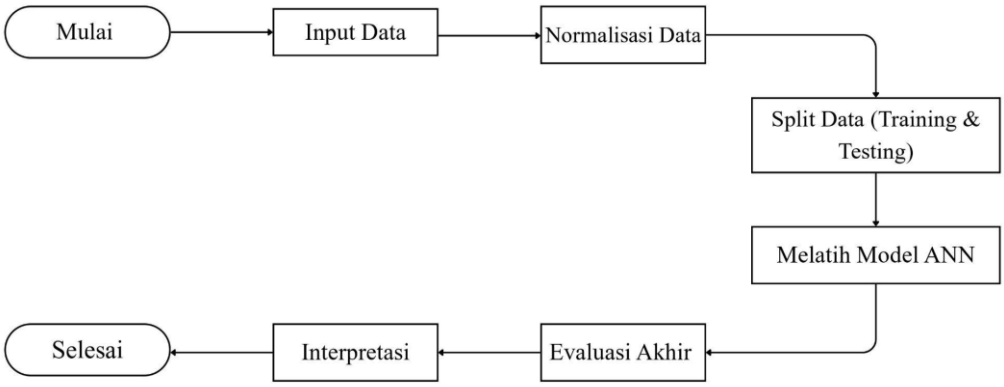
Melihat kondisi tersebut, penelitian ini berfokus pada pembangunan model prediksi konsentrasi PM2.5 di DKI Jakarta tahun 2023 dengan menerapkan *Artificial Neural Network* berbasis algoritma *backpropagation*. Model yang dikembangkan diharapkan mampu memberikan prediksi yang akurat sehingga dapat mendukung pengembangan sistem peringatan dini dan membantu pemerintah daerah dalam merumuskan kebijakan pengendalian kualitas udara secara lebih efektif [7].

2. METODE PENELITIAN

Tahapan Penelitian

Metode penelitian ini diawali dengan menginput data kualitas udara, kemudian dilakukan preprocessing berupa pemeriksaan dan imputasi missing value. Data selanjutnya dinormalisasi dan dibagi menjadi data training sebesar 80% dan data testing sebesar 20%. Model *Artificial Neural Network* (ANN) dibangun dengan empat neuron pada input layer, satu hidden layer berisi tiga neuron, dan satu *neuron* pada *output layer*. Proses pelatihan

menggunakan algoritma *backpropagation* dengan *threshold error* sebesar 0,01 dan pemilihan learning rate optimal berdasarkan nilai MAPE terkecil. Setelah model dilatih hingga perubahan error berada di bawah *threshold*, dilakukan evaluasi menggunakan MAPE dan MSE, kemudian hasil prediksi dibandingkan dengan data aktual untuk memperoleh interpretasi akhir. Grafik alur analisis ditampilkan pada Gambar 1.



Gambar 1. Tahapan Penelitian

Pengumpulan Data

Data penelitian ini merupakan data sekunder Indeks Standar Pencemar Udara (ISPU) tahun 2023 dari Dinas Komunikasi, Informatika, dan Statistik Provinsi DKI Jakarta yang diperoleh melalui situs satudata.jakarta.go.id. Objek penelitian mencakup data harian Bundaran HI periode 05 Mei 2023 hingga 30 November 2023 sebanyak 214 observasi. Penelitian menggunakan lima variabel, yaitu PM2.5 (y), Sulfur Dioksida/SO_2 (x_1), Karbon Monoksida/CO (x_2), Ozon/O_3 (x_3), dan Nitrogen Dioksida/NO_2 (x_4), yang seluruhnya berupa data numerik dengan satuan $\mu g/m^3$.

Pre-processing Data

Pre-processing merupakan tahap penting dalam menyiapkan data agar layak digunakan dalam pemodelan [8]. Tahap ini mencakup beberapa langkah utama, yaitu:

Data Cleaning

Dilakukan untuk menangani missing value dan memastikan tidak terdapat nilai ekstrem atau tidak wajar yang dapat mengganggu proses pelatihan model.

Data Selection

Pemilihan variabel dilakukan berdasarkan kebutuhan penelitian, yaitu PM2.5 sebagai variabel target serta SO_2, CO, O_3, dan NO_2 sebagai variabel prediktor.

Normalisasi Data

Normalisasi diterapkan agar seluruh variabel berada pada skala yang seragam sehingga mendukung kinerja ANN. Metode yang digunakan adalah Min-Max normalization dengan rumus:

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \quad (1)$$

Polusi Udara

Polusi udara adalah pelepasan polutan berbahaya ke atmosfer yang mengganggu kesehatan manusia dan lingkungan [9]. Aktivitas seperti emisi industri, asap kendaraan, dan pembakaran ilegal meningkatkan kadar polutan seperti CO, CO_2, PM, NO_2, dan O_3 yang

dapat memicu penyakit pernapasan dan jantung [10]. Dalam beberapa tahun terakhir, masalah ini semakin serius di DKI Jakarta yang berpenduduk lebih dari 10 juta jiwa, di mana tingginya mobilitas dan penggunaan transportasi menjadi faktor utama meningkatnya pencemaran udara.

Artificial Neural Network

Artificial Neural Network (ANN) merupakan salah satu metode *machine learning* yang banyak digunakan karena kemampuannya mempelajari pola kompleks dan melakukan prediksi secara efektif [11]. Terinspirasi dari cara kerja jaringan saraf biologis, ANN terdiri atas tiga lapisan utama *input layer*, *hidden layer*, dan *output layer* di mana data diteruskan dari *input*, diproses pada *hidden layer*, kemudian menghasilkan keluaran pada *output* layer.

Algoritma *Backpropagation*

Backpropagation merupakan teknik pelatihan pada jaringan *multilayer perceptron* yang digunakan untuk meminimalkan kesalahan prediksi melalui pembaruan bobot secara bertahap [12]. Dikembangkan pertama kali oleh Paul Werbos pada tahun 1974, algoritma ini menjadi salah satu metode paling populer karena efektivitasnya dalam menangani jaringan *multilayer* yang kompleks. Dalam penelitian ini digunakan algoritma *backpropagation* dengan fungsi aktivasi *logistic* pada *hidden layer* maupun *output layer*, yang dinyatakan dengan persamaan:

$$\varphi(x) = \frac{1}{1 + e^{-x}} \tag{2}$$

Evaluasi Kinerja Model Prediksi

Evaluasi model dilakukan untuk mengukur tingkat kesalahan antara nilai prediksi dan nilai aktual. Pada penelitian berbasis ANN, ukuran *error* yang umum digunakan meliputi:

1. *Mean Squared Error* (MSE)
   Mengukur rata-rata kesalahan kuadrat antara nilai aktual dan prediksi. Nilai MSE yang lebih kecil menunjukkan performa model yang lebih baik.
   $$MSE = \frac{1}{n}\sum(y_i - \hat{y_i})^2 \tag{3}$$

2. *Mean Absolute Percentage Error* (MAPE)
   Mengukur tingkat kesalahan dalam bentuk persentase, sehingga memudahkan perbandingan antar model.
   $$MAPE = \frac{1}{n}\sum \left| \frac{y_i - \hat{y_i}}{y_i} \right| \times 100\% \tag{4}$$

3. Koefisien Determinasi (R^2)
   Mengukur proporsi variasi data target yang dapat dijelaskan oleh model. Nilai R^2 berkisar antara 0–1, semakin tinggi nilai R^2, semakin baik kemampuan model dalam menjelaskan variasi data [13].
   $$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{5}$$

Model peramalan dikatakan memiliki kinerja *sangat baik* apabila menghasilkan nilai MAPE di bawah 10% [14].

Prediksi

Prediksi adalah proses memperkirakan nilai atau kondisi di masa mendatang dengan memanfaatkan informasi data historis dan pola yang terjadi sebelumnya [15].

3. HASIL DAN PEMBAHASAN

***Preprocessing* Data**

Sebelum dilakukan analisis, data terlebih dahulu dilakukan *preprocessing* dengan data *cleaning,* data *selection,* dan normalisasi data. Data ditemukan terdapat 9 data *missing value* yaitu seluruh variabel pada data ke-153 dan variabel CO untuk data ke-167 hingga data ke-170. Nilai yang hilang diatasi menggunakan metode imputasi rata-rata (*mean imputation*). Pemilihan variabel didasarkan pada penelitian terdahulu dan tujuan penelitian yaitu untuk melihat pengaruh SO_2 (sulfur dioksida), CO (karbon monoksida), O_3 (ozon), dan NO_2 (nitrogen dioksida) terhadap PM 2,5. Selanjutnya, dilakukan normalisasi data dengan menggunakan *Min-Max Scaling* di mana skalanya ialah 0 hingga 1. Proses pengujian (*training*) dilakukan terhadap 80% data yaitu sebanyak 171 data.

Arsitektur ANN

Penelitian ini menggunakan 4 *input neuron* yaitu SO_2 (x_1), CO (x_2), O_3 (x_3), dan NO_2 (x_4) dengan PM 2,5 (Y) sebagai target. Jumlah *neuron* dan *hidden layer* ditentukan berdasarkan *rule of thumb*. Di mana, jumlah *hidden layer* yang disarankan adalah sebanyak 2 *layer* maka dalam penelitian ini *hidden layer* yang digunakan sebanyak 2 *hidden layer.* Untuk jumlah *neuron* pada *hidden layer* harus setidaknya lebih besar dari dua kali banyaknya input, maka total *neuron hidden layer* yang digunakan sebanyak 8 *neuron* (5 *neuron* di hidden *layer* pertama dan 3 *neuron* di *hidden layer* kedua).

Penentuan Nilai *Learning Rate*

Untuk nilai *learning rate* ditentukan berdasarkan perbandungan nilai MAPE terkecil dengan nilai *learning rate* ialah 0,0005; 0,0001; 0,00005.

Tabel 1. Nilai Learning Rate berdasarkan Nilai MAPE

Nilai *Learning Rate*	Nilai MAPE
0,0005	11,14132
0,0001	11,14114
0,00005	11,14111

Berdasarkan nilai MAPE pada Tabel 5, maka nilai *learning rate* yang digunakan ialah sebesar 0,00005.

Proses *Backpropagation*

Fungsi aktivasi yang digunakan dalam *hidden layer* adalah logistik sigmoid dan fungsi aktivasi dalam *output layer* adalah linear. Berdasarkan penentuan tersebut, maka berikut proses untuk mendapatkan nilai prediksi:

Tabel 2. Nilai Bobot Akhir Layer 1

$w_{i,k}^{(1)}$	1	2	3	4	5

1	-0,6045	1,6007	0,8440	1,7721	-1,0971
2	-0,2186	0,2698	-0,1041	0,6472	-0,2206
3	1,5323	-1,3006	0,3228	-1,9589	-1,0411
4	0,0681	-0,6539	0,1575	0,6318	-0,7400
5	0,1506	-0,8067	-1,5281	-0,2120	-0,6197

Tabel tersebut merupakan tabel bobot untuk *hidden layer* pertama berdasarkan algoritma *backpropagation* dengan inisialisasi bobot secara *random.* Setelah bobot pada *hidden layer* pertama didapatkan, maka dapat dilanjutkan dengan jumlah terboboti dengan perhitungan seperti berikut dengan *i* sebagai pengamatan ke-*i*:

$$z_{i1}^{(1)} = -0.6045 + \left(-0.2186 \times a_{i1}^{(0)}\right) + \left(1.5323 \times a_{i2}^{(0)}\right) + \left(0.0681 \times a_{i3}^{(0)}\right) + \left(0.1506 \times a_{i4}^{(0)}\right)$$

$$\vdots$$

$$z_{i5}^{(1)} = -1.0971 + \left(-0.2206 \times a_{i1}^{(0)}\right) + \left(-1.0411 \times a_{i2}^{(0)}\right) + \left(-0.7400 \times a_{i3}^{(0)}\right) + \left(-0.6197 \times a_{i4}^{(0)}\right)$$

Hasil dari jumlah terboboti ini kemudian dimasukkan ke dalam fungsi aktivasi, sehingga diperoleh output untuk *hidden layer* pertama ($\varphi(z^{(1)})$) melalui perhitungan berikut dengan *i* sebagai pengamatan ke-*i*:

$$a_{i1}^{(1)} = \left[a_{i1}^{(1)}\right] = \varphi\left(z_{i1}^{(1)}\right) = \left[\frac{1}{1 + \exp\left(-z_{i1}^{(1)}\right)}\right]$$

$$:$$

$$:$$

$$a_{i5}^{(1)} = \left[a_{i5}^{(1)}\right] = \varphi\left(z_{i5}^{(1)}\right) = \left[\frac{1}{1 + \exp\left(-z_{i5}^{(1)}\right)}\right]$$

Output ini selanjutnya menjadi *input* bagi *hidden layer* kedua ($a^{(1)}$), di mana setiap *neuron* pada *hidden layer* kedua dikalikan dengan bobotnya masing-masing ($W^{(2)}$) dan ditambahkan bias ($a_0^{(1)}$). Bobot untuk *hidden layer* kedua dapat dilihat pada tabel berikut:

Tabel 3. Nilai Bobot Akhir Layer 2

$w_{i,k}^{(2)}$	1	2	3
1	-1,5872	-0,6125	-0,0904
2	0,8381	0,7736	-0,3141
3	0,1381	0,7336	-0,3655
4	-1,4740	1,0141	-0,6258
5	1,2700	0,5261	-0,2160
6	0,3130	0,6369	-1,2328

Perkalian *input* dari *hidden layer* kedua $(a^{(1)})$ dengan bobot masing-masing *neuron* ($W^{(2)}$), ditambah dengan bias ($a_0^{(1)}$), menghasilkan jumlah terboboti untuk *hidden layer* kedua ($z^{(2)}$) dengan perhitungan seperti berikut dengan *i* sebagai pengamatan ke-*i*:

$$z_{i1}^{(2)} = -1{,}5872 + \left(0{,}8381 \times a_{i1}^{(1)}\right) + \left(0{,}1381 \times a_{i2}^{(1)}\right) + \left(-1{,}4740 \times a_{i3}^{(1)}\right) + \left(1{,}27 \times a_{i4}^{(1)}\right) + \left(0{,}313 \times a_{i5}^{(1)}\right)$$

$$\vdots$$

$$z_{i3}^{(2)} = -0{,}0904 + \left(-0{,}3141 \times a_{i1}^{(1)}\right) + \left(-0{,}3655 \times a_{i2}^{(1)}\right) + \left(-0{,}6258 \times a_{i3}^{(1)}\right) + \left(-0{,}216 \times a_{i4}^{(1)}\right) + \left(-1{,}2328 \times a_{i4}^{(1)}\right)$$

Nilai ini kemudian dimasukkan ke dalam fungsi aktivasi sehingga diperoleh *output* dari *hidden layer* kedua ($\varphi(z^{(2)})$) melalui perhitungan berikut dengan *i* sebagai pengamatan ke-*i*:

$$a_{i1}^{(2)} = \left[a_{i1}^{(2)}\right] = \varphi\left(z_{i1}^{(2)}\right) = \left[\frac{1}{1 + \exp\left(-z_{i1}^{(2)}\right)}\right]$$

$$\vdots$$

$$a_{i3}^{(2)} = \left[a_{i3}^{(2)}\right] = \varphi\left(z_{i3}^{(2)}\right) = \left[\frac{1}{1 + \exp\left(-z_{i3}^{(2)}\right)}\right]$$

Output ini selanjutnya digunakan sebagai *input* $(a^{(2)})$ untuk *output layer*, di mana setiap nilai $(a^{(2)})$ dikalikan dengan bobot ($W^{(3)}$) dan ditambahkan bias ($a_0^{(2)}$) untuk menghasilkan prediksi akhir ($\varphi(z^{(3)})$). Bobot yang digunakan untuk memperoleh output dapat dilihat pada tabel berikut:

Tabel 4. Nilai Bobot Akhir Layer 3

$w_{i,k}^{(3)}$	1
1	1,6707
2	1,3881
3	-1,9024
4	-0,1291

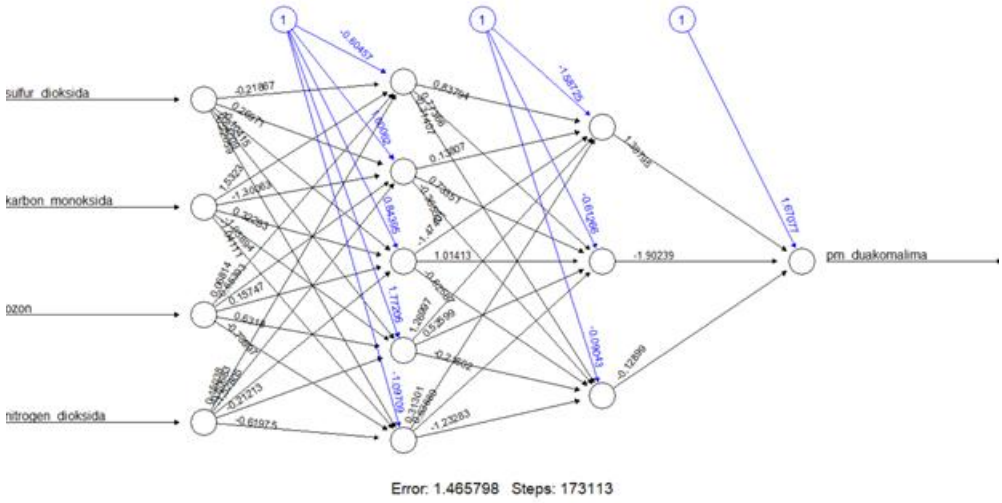
Perkalian *input* dari *hidden layer* kedua $(a^{(2)})$ dengan bobot masing-masing *neuron* ($W^{(3)}$), ditambah dengan bias ($a_0^{(3)}$), menghasilkan jumlah terboboti untuk *hidden layer* kedua ($z^{(3)}$) dengan perhitungan seperti berikut dengan *i* sebagai pengamatan ke-*i*:

$$z_{i1}^{(3)} = 1{,}6707 + \left(1{,}3881 \times a_{i1}^{(2)}\right) + \left(-1{,}9024 \times a_{i2}^{(2)}\right) + \left(-0{,}1291 \times a_{i3}^{(2)}\right)$$

Nilai dari hasil tersebut, kemudian dimasukkan ke dalam fungsi aktivasi sehingga diperoleh *output* dari *hidden layer* kedua ($\varphi(z^{(3)})$) melalui perhitungan berikut dengan *i* sebagai pengamatan ke-*i*:

$$a_{i1}^{(3)} = \left[a_{i1}^{(3)}\right] = \varphi\left(z_{i1}^{(3)}\right) = \left[\frac{1}{1 + \exp\left(-z_{i1}^{(3)}\right)}\right]$$

Untuk Gambaran lebih lengkapnya dapat dilihat pada gambar berikut:



Gambar 2. Arsitektur ANN

Hasil *output* ini dilanjutkan dengan denormalisasi agar hasil *output* kembali ke hasil aslinya untuk membandingkan antara data aktual dengan hasil prediksi.

Evaluasi Model ANN

Menghitung nilai MAPE dilakukan dengan menggunakan data *testing* yang telah disesuaikan melalui pembagian data yang dilakukan sebelumnya yaitu 20% dari data atau sebanyak 43 data. Nilai MAPE berasal dari nilai data aktual dan data prediksi yang dihitung menggunakan persamaan (3),(4), dan (5). Didapat dari proses ANN *Backpropagation* seperti Tabel 1 berikut.

Tabel 5. Nilai Hasil Perhitungan MAPE

Simulasi	MAPE	MSE	R^2
Training	9,4522737	112,4808	0,1689
Testing	11,14132	124,4607	0,2609

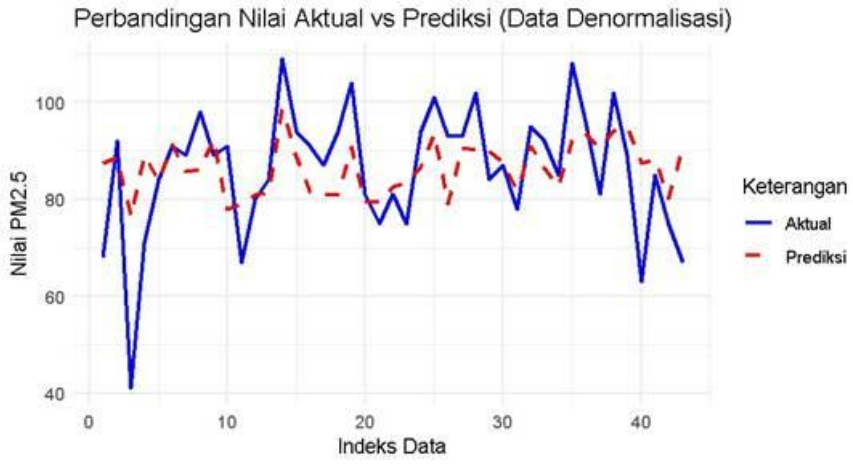
Hasil evaluasi model ANN menunjukkan nilai MSE sebesar 124,46 dan MAPE 11,14%, yang menandakan model mampu menangkap pola data dengan baik meskipun beberapa baris mengalami kesulitan prediksi. Nilai MAPE pada data training lebih rendah dibanding data testing, sedangkan R^2 pada data testing lebih tinggi, menunjukkan model mampu menjelaskan 16–26% variasi data target. Hal ini mengindikasikan bahwa model masih memiliki ruang perbaikan dalam menangkap hubungan antara variabel *input* dan *output*.

Hasil Prediksi

Setelah melalui proses pelatihan dan di lakukan pengujian pada data *testing* dan *training*, dihasilkan hasil prediksi secara keseluruh. Nilai hasil prediksi akan dibandingkan dengan nilai aktual untuk mengetahui akurasi dari model ANN. Hasil prediksi secara lengkap disajikan dalam tabel dan gambar berikut:

Tabel 6. Nilai Aktual vs Prediksi Data Testing

No	Aktual	Prediksi	Selisih
1	68	87.48	19.48
2	92	88.48	3.52
3	41	76.39	35.39
:	:	:	:
:	:	:	:
41	85	88.34	3.34
42	75	80.22	5.22
43	67	90.69	23.69



Gambar 3. Nilai Aktual vs Prediksi Data Testing

Secara keseluruhan, model tersebut dapat mengikuti pola pergerakan dari data kualitas udara di Bundaran HI DKI Jakarta, meskipun terdapat terdapat beberapa titik nilai prediksi dimana berbeda dengan nilai aktual. Hal tersebut menunjukkan bahwa model masih cukup akurat, meski terdapat sedikit perbedaan.

4. KESIMPULAN

Berdasarkan hasil penelitian, model *Artificial Neural Network* (ANN) dengan algoritma *Backpropagation* berhasil dibangun untuk memprediksi konsentrasi PM2.5 harian di DKI Jakarta tahun 2023 menggunakan variabel SO_2, CO, O_3, dan NO_2. Setelah melalui tahap preprocessing, normalisasi, pembagian data, serta penentuan arsitektur jaringan 4-5-3-1 dengan learning rate terbaik sebesar 0.00005, model menghasilkan nilai MAPE sebesar 11,14% pada data *testing*. Nilai tersebut menunjukkan bahwa model cukup mampu mengikuti pola perubahan PM2.5, meskipun belum mencapai tingkat akurasi yang sangat baik (MAPE < 10%). Secara keseluruhan, model ANN ini dapat digunakan sebagai pendekatan awal untuk memprediksi kualitas udara, namun performanya masih dapat ditingkatkan melalui optimasi arsitektur dan penambahan variabel yang lebih relevan.

UCAPAN TERIMA KASIH

Penulis menyampaikan rasa terima kasih yang sebesar-besarnya kepada Bapak Suliadi, S.Si., M.Si., Ph.D., selaku dosen pengampu mata kuliah *Machine Learning*, atas bimbingan, arahan, serta dukungan ilmiah yang sangat berharga dalam proses penyusunan artikel ini. Nasihat dan pengetahuan yang beliau berikan telah membantu penulis dalam memahami konsep, metode, serta analisis yang digunakan dalam penelitian ini.

DAFTAR PUSTAKA

[1] Dinas Lingkungan Hidup Provinsi DKI Jakarta, “Kajian Pemantauan Kualitas Udara di Provinsi DKI Jakarta,” 2023, Accessed: Nov. 15, 2025. [Online]. Available: https://dev.dinaslhdki.id/uploads/images/galery/udara-2023-la_20250702130132.pdf

[2] IQAir, “World’s Most Polluted Cities 2023 (PM2.5 concentration),” 2023, Accessed: Nov. 15, 2025. [Online]. Available: https://www.iqair.com/world-most-polluted-cities

[3] World Health Organization, “WHO global air quality guidelines: Particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide,” 2021, Accessed: Nov. 15, 2025. [Online]. Available: https://www.who.int/publications/i/item/9789240034228

[4] G. Ayu, N. Lestari, N. Dwi, and A. Mahendra, “Prediksi Kualitas Udara dengan Menggunakan Metode Long Short-Term Memory dan Artificial Neural Network,” 2023, Accessed: Nov. 15, 2025. [Online]. Available: https://jsi.stikom-bali.ac.id/index.php/jsi/article/view/565/243

[5] A. Rivero-Cacho, G. Sánchez-Barroso, P. Pastor-Pérez, and J. García-Sanz-Calcedo, “Forecasting indoor air quality in high-risk operating theatres in hospitals using

Artificial Neural Networks," *Journal of Building Engineering*, vol. 111, Oct. 2025, doi: 10.1016/j.jobe.2025.113339.

[6] N. Hikmah, S. Bahri, and I. Irwansyah, "Jaringan Syaraf Tiruan untuk Memprediksi Kadar Polutan Ozon di Kota Mataram," *EIGEN MATHEMATICS JOURNAL*, pp. 70–85, Dec. 2022, doi: 10.29303/emj.v5i2.129.

[7] I. N. K. Wardana, J. W. Gardner, and S. A. Fahmy, "Optimising deep learning at the edge for accurate hourly air quality prediction," *Sensors (Switzerland)*, vol. 21, no. 4, pp. 1–28, Feb. 2021, doi: 10.3390/s21041064.

[8] S. A. Alasadi and W. S. Bhaya, "Review of data preprocessing techniques in data mining," *Journal of Engineering and Applied Sciences*, vol. 12, no. 16, pp. 4102–4107, Sep. 2017, doi: 10.3923/jeasci.2017.4102.4107.

[9] S. Aswatha *et al.*, "Smart air pollution monitoring system," *Global Nest Journal*, vol. 25, no. 3, pp. 125–129, Mar. 2023, doi: 10.30955/gnj.004396.

[10] K. Kumar and B. P. Pande, "Air pollution prediction with machine learning: a case study of Indian cities," *International Journal of Environmental Science and Technology*, vol. 20, no. 5, pp. 5333–5348, May 2023, doi: 10.1007/s13762-022-04241-5.

[11] K. Alrasheed, M. Al Ballat, E. Soliman, and H. Albader, "Artificial Neural Network-based cost estimation for public construction projects in Kuwait," *Journal of Engineering Research*, Sep. 2025, doi: 10.1016/j.jer.2025.09.001.

[12] H. I. Hussein *et al.*, "Design of artificial neural networks for darcy-forchheimer flow of boger hybrid nanofluid with CattaneoChristov theory: Thermofluidic applications," *International Journal of Thermofluids*, vol. 30, p. 101473, Nov. 2025, doi: 10.1016/j.ijft.2025.101473.

[13] I. N. T. Adnyana, I. G. P. S. Wijaya, and M. A. Albar, "Jaringan Syaraf Tiruan Model Backpropagation untuk Peramalan Suhu Minimum dan Maksimum, Kelembaban, Tekanan Udara, Jumlah Hari Hujan, dan Curah Hujan Bulanan di Kota Mataram," *Journal of Computer Science and Informatics Engineering (J-Cosine)*, vol. 3, no. 2, Dec. 2019, doi: 10.29303/jcosine.v3i2.259.

[14] S. Maslamah, Aripriharta, A. N. Handayani, G.-J. Horng, and M. cahyo Bagaskoro, "Forecasting New State University Student Admissions Through The XII Level Student Achievement Pathway Smk Negeri 1 Bandung Tulungagung Using Arima Method," *Journal of Education Technology*, vol. 9, no. 1, Apr. 2025, doi: 10.23887/jet.v9i1.86015.

[15] Y. Hendra, H. Mukhtar, and R. Hafsari, "PREDIKSI CURAH HUJAN DI KOTA PEKANBARU MENGGUNAKAN LSTM (LONG SHORT TERM MEMORY)," 2023.

UTS_Machine Learning_Kel 6

by Machine Learning Uts

Submission date: 17-Nov-2025 08:41AM (UTC+0700)
Submission ID: 2817247814
File name: UTS_Machine_Learning_Kel_6.pdf (581.42K)
Word count: 3282
Character count: 19370

PENGGUNAAN *ARTIFICIAL NEURAL NETWORK* DENGAN *BACKPROPAGATION* UNTUK MEMPREDIKSI KUALITAS UDARA KHUSUS PM 2.5 DKI JAKARTA TAHUN 2023

Hana Nurul Wahidah[1], Keysha Jauzi Althaff[2], Muhammad Wildan Ramadhan[3], Rusdian Mulyana[4], Suliadi[5]

[1,2,3,4,5] Program Studi Statistika, Fakultas MIPA, Universitas Islam Bandung

e-mail: 10060122038@unisba.ac.id

Abstrak

Penelitian ini bertujuan untuk memprediksi konsentrasi polutan PM2.5 di DKI Jakarta pada tahun 2023 menggunakan metode *Artificial Neural Network* (ANN) dengan algoritma *backpropagation*. Data harian kualitas udara dari Stasiun Bundaran HI periode Mei–November 2023 digunakan sebagai dataset, dengan variabel input meliputi SO_2, CO, O_3, dan NO_2. Proses *preprocessing* dilakukan melalui pemeriksaan dan imputasi *missing value*, seleksi variabel, serta normalisasi menggunakan metode *min-max scaling*. Data dibagi menjadi data *training* (80%) dan *testing* (20%). Arsitektur jaringan terdiri dari 4 *neuron* input, dua *hidden layer* (masing-masing 5 dan 3 neuron), serta 1 *neuron output*, dengan fungsi aktivasi *logistic sigmoid* pada *hidden layer* dan fungsi linear pada *output layer*. Hasil evaluasi menunjukkan nilai MAPE sebesar 11,14%, MSE sebesar 124,46, serta koefisien determinasi (R^2) sebesar 0,2609 pada data *testing*. Meskipun akurasi model belum optimal, ANN mampu menangkap pola hubungan non-linear antara variabel pencemar udara dan konsentrasi PM2.5 secara cukup baik. Kendala utama penelitian meliputi keterbatasan jumlah data serta kompleksitas dalam pemilihan parameter optimal ANN. Model ini diharapkan dapat menjadi dasar pengembangan sistem prediksi kualitas udara yang lebih akurat di masa mendatang.

Kata Kunci: *Artificial Neural Network*; DKI Jakarta; Kualitas Udara PM 2.5; Prediksi

Abstract

This study aims to predict PM2.5 concentrations in DKI Jakarta during 2023 using an Artificial Neural Network (ANN) with the Backpropagation algorithm. Daily air quality data from the Bundaran HI monitoring station, covering the period from May to November 2023, were used as the dataset. The input variables included SO_2, CO, O_3, and NO_2. The preprocessing stage consisted of handling missing values through mean imputation, selecting relevant variables, and applying min–max normalization. The dataset was then divided into training data (80%) and testing data (20%). The ANN architecture consisted of four input neurons, two hidden layers with five and three neurons respectively, and one output neuron, employing the logistic sigmoid activation function in the hidden layers and a linear function in the output layer. Evaluation results show a MAPE of 11.14%, MSE of 124.46, and an R^2 value of 0.2609 on the testing data. Although the model has not achieved optimal accuracy, it is capable of capturing non-linear relationships between air pollutant variables and PM2.5 concentrations reasonably well. The main challenges encountered include limited data availability and the complexity of determining optimal ANN parameters. This model is expected to serve as a foundation for developing more accurate air quality prediction systems in the future.

Keywords: *Artificial Neural Network; DKI Jakarta; PM 2.5 Air Quality; Prediction*

1. PENDAHULUAN

Kualitas udara merupakan salah satu isu lingkungan yang krusial di wilayah perkotaan, terutama di daerah dengan tingkat aktivitas transportasi dan industri yang tinggi. DKI Jakarta sebagai pusat pemerintahan dan kegiatan ekonomi nasional menghadapi permasalahan pencemaran udara yang meningkat dari tahun ke tahun. Salah satu polutan yang paling berbahaya adalah PM2.5, yaitu partikulat halus berukuran kurang dari 2,5 mikrometer yang dapat masuk hingga ke saluran pernapasan bagian dalam. Berdasarkan laporan Dinas Lingkungan Hidup Provinsi DKI Jakarta[1], rata-rata konsentrasi PM2.5 di wilayah ini mencapai 39,2 µg/m³, jauh melampaui ambang batas aman WHO sebesar 5 µg/m³ [2]. Kondisi ini menimbulkan dampak serius bagi kesehatan masyarakat dan menurunkan kualitas hidup penduduk [3].

Tingginya paparan PM2.5 tersebut memunculkan kebutuhan akan sistem prediksi yang mampu memberikan gambaran konsentrasi polutan secara lebih akurat dan responsif. Pergerakan PM2.5 dipengaruhi oleh berbagai faktor seperti kepadatan lalu lintas, emisi industri, hingga kondisi cuaca harian. Kompleksitas hubungan antar variabel tersebut membuat pendekatan analisis linier tradisional kurang memadai untuk menggambarkan dinamika polutan yang bersifat *non-linear*.

Untuk menjawab kebutuhan tersebut, pendekatan berbasis *Artificial Neural Network* (ANN) dengan algoritma *backpropagation* menjadi salah satu metode yang relevan. ANN mampu mempelajari pola-pola kompleks dalam data runtun waktu, beradaptasi terhadap variasi data, serta menekan tingkat kesalahan prediksi melalui proses pelatihan berulang. Dengan kemampuan generalisasi yang baik, metode ini berpotensi memberikan prediksi kualitas udara yang lebih stabil, khususnya untuk parameter PM2.5.

Sejumlah penelitian sebelumnya juga telah memperkuat efektivitas metode ini dalam konteks kualitas udara. Model ANN terbukti mampu memprediksi parameter polutan seperti PM10, SO_2, CO, O_3, dan PM2.5 dengan tingkat kesalahan yang rendah [4]. Pengembangan ANN berbasis NARX juga ditemukan dapat meningkatkan akurasi prediksi kualitas udara dalam ruangan [5]. Selain itu, pemodelan kadar ozon menggunakan ANN di Kota Mataram menunjukkan tingkat akurasi yang tinggi dengan koefisien determinasi mencapai 95,67% [6]. Meskipun demikian, performa ANN tetap dipengaruhi oleh pemilihan parameter jaringan, jumlah data, serta faktor eksternal yang memerlukan proses optimasi lebih lanjut.

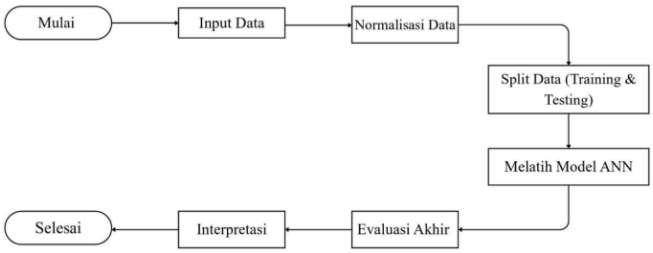
Melihat kondisi tersebut, penelitian ini berfokus pada pembangunan model prediksi konsentrasi PM2.5 di DKI Jakarta tahun 2023 dengan menerapkan *Artificial Neural Network* berbasis algoritma *backpropagation*. Model yang dikembangkan diharapkan mampu memberikan prediksi yang akurat sehingga dapat mendukung pengembangan sistem peringatan dini dan membantu pemerintah daerah dalam merumuskan kebijakan pengendalian kualitas udara secara lebih efektif [7].

2. METODE PENELITIAN

Tahapan Penelitian

Metode penelitian ini diawali dengan menginput data kualitas udara, kemudian dilakukan preprocessing berupa pemeriksaan dan imputasi missing value. Data selanjutnya dinormalisasi dan dibagi menjadi data training sebesar 80% dan data testing sebesar 20%. Model *Artificial Neural Network* (ANN) dibangun dengan empat neuron pada input layer, satu hidden layer berisi tiga neuron, dan satu *neuron* pada *output layer*. Proses pelatihan

menggunakan algoritma *backpropagation* dengan *threshold error* sebesar 0,01 dan pemilihan learning rate optimal berdasarkan nilai MAPE terkecil. Setelah model dilatih hingga perubahan error berada di bawah *threshold*, dilakukan evaluasi menggunakan MAPE dan MSE, kemudian hasil prediksi dibandingkan dengan data aktual untuk memperoleh interpretasi akhir. Grafik alur analisis ditampilkan pada Gambar 1.



Gambar 1. Tahapan Penelitian

Pengumpulan Data

Data penelitian ini merupakan data sekunder Indeks Standar Pencemar Udara (ISPU) tahun 2023 dari Dinas Komunikasi, Informatika, dan Statistik Provinsi DKI Jakarta yang diperoleh melalui situs satudata.jakarta.go.id. Objek penelitian mencakup data harian Bundaran HI periode 05 Mei 2023 hingga 30 November 2023 sebanyak 214 observasi. Penelitian menggunakan lima variabel, yaitu PM2.5 (y), Sulfur Dioksida/SO_2 (x_1), Karbon Monoksida/CO (x_2), Ozon/O_3 (x_3), dan Nitrogen Dioksida/NO_2 (x_4), yang seluruhnya berupa data numerik dengan satuan $\mu g/m^3$.

Pre-processing Data

Pre-processing merupakan tahap penting dalam menyiapkan data agar layak digunakan dalam pemodelan [8]. Tahap ini mencakup beberapa langkah utama, yaitu:

Data Cleaning

Dilakukan untuk menangani missing value dan memastikan tidak terdapat nilai ekstrem atau tidak wajar yang dapat mengganggu proses pelatihan model.

Data Selection

Pemilihan variabel dilakukan berdasarkan kebutuhan penelitian, yaitu PM2.5 sebagai variabel target serta SO_2, CO, O_3, dan NO_2 sebagai variabel prediktor.

Normalisasi Data

Normalisasi diterapkan agar seluruh variabel berada pada skala yang seragam sehingga mendukung kinerja ANN. Metode yang digunakan adalah Min-Max normalization dengan rumus:

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \quad (1)$$

Polusi Udara

Polusi udara adalah pelepasan polutan berbahaya ke atmosfer yang mengganggu kesehatan manusia dan lingkungan [9]. Aktivitas seperti emisi industri, asap kendaraan, dan pembakaran ilegal meningkatkan kadar polutan seperti CO, CO_2, PM, NO_2, dan O_3 yang

dapat memicu penyakit pernapasan dan jantung [10]. Dalam beberapa tahun terakhir, masalah ini semakin serius di DKI Jakarta yang berpenduduk lebih dari 10 juta jiwa, di mana tingginya mobilitas dan penggunaan transportasi menjadi faktor utama meningkatnya pencemaran udara.

Artificial Neural Network

Artificial Neural Network (ANN) merupakan salah satu metode *machine learning* yang banyak digunakan karena kemampuannya mempelajari pola kompleks dan melakukan prediksi secara efektif [11]. Terinspirasi dari cara kerja jaringan saraf biologis, ANN terdiri atas tiga lapisan utama *input layer*, *hidden layer*, dan *output layer* di mana data diteruskan dari *input*, diproses pada *hidden layer*, kemudian menghasilkan keluaran pada *output* layer.

Algoritma *Backpropagation*

Backpropagation merupakan teknik pelatihan pada jaringan *multilayer perceptron* yang digunakan untuk meminimalkan kesalahan prediksi melalui pembaruan bobot secara bertahap [12]. Dikembangkan pertama kali oleh Paul Werbos pada tahun 1974, algoritma ini menjadi salah satu metode paling populer karena efektivitasnya dalam menangani jaringan *multilayer* yang kompleks. Dalam penelitian ini digunakan algoritma *backpropagation* dengan fungsi aktivasi *logistic* pada *hidden layer* maupun *output layer*, yang dinyatakan dengan persamaan:

$$\varphi(x) = \frac{1}{1 + e^{-x}} \tag{2}$$

Evaluasi Kinerja Model Prediksi

Evaluasi model dilakukan untuk mengukur tingkat kesalahan antara nilai prediksi dan nilai aktual. Pada penelitian berbasis ANN, ukuran *error* yang umum digunakan meliputi:

1. *Mean Squared Error* (MSE)
   Mengukur rata-rata kesalahan kuadrat antara nilai aktual dan prediksi. Nilai MSE yang lebih kecil menunjukkan performa model yang lebih baik.
   $$MSE = \frac{1}{n}\sum(y_i - \hat{y}_i)^2 \tag{3}$$
2. *Mean Absolute Percentage Error* (MAPE)
   Mengukur tingkat kesalahan dalam bentuk persentase, sehingga memudahkan perbandingan antar model.
   $$MAPE = \frac{1}{n}\sum \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100\% \tag{4}$$
3. Koefisien Determinasi (R^2)
   Mengukur proporsi variasi data target yang dapat dijelaskan oleh model. Nilai R^2 berkisar antara 0–1, semakin tinggi nilai R^2, semakin baik kemampuan model dalam menjelaskan variasi data [13].
   $$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \tag{5}$$

Model peramalan dikatakan memiliki kinerja *sangat baik* apabila menghasilkan nilai MAPE di bawah 10% [14].

Prediksi

Prediksi adalah proses memperkirakan nilai atau kondisi di masa mendatang dengan memanfaatkan informasi data historis dan pola yang terjadi sebelumnya [15].

3. HASIL DAN PEMBAHASAN

***Preprocessing* Data**

Sebelum dilakukan analisis, data terlebih dahulu dilakukan *preprocessing* dengan data *cleaning*, data *selection,* dan normalisasi data. Data ditemukan terdapat 9 data *missing value* yaitu seluruh variabel pada data ke-153 dan variabel CO untuk data ke-167 hingga data ke-170. Nilai yang hilang diatasi menggunakan metode imputasi rata-rata (*mean imputation*). Pemilihan variabel didasarkan pada penelitian terdahulu dan tujuan penelitian yaitu untuk melihat pengaruh SO_2 (sulfur dioksida), CO (karbon monoksida), O_3 (ozon), dan NO_2 (nitrogen dioksida) terhadap PM 2,5. Selanjutnya, dilakukan normalisasi data dengan menggunakan *Min-Max Scaling* di mana skalanya ialah 0 hingga 1. Proses pengujian (*training*) dilakukan terhadap 80% data yaitu sebanyak 171 data.

Arsitektur ANN

Penelitian ini menggunakan 4 *input neuron* yaitu SO_2 (X_1), CO (X_2), O_3 (X_3), dan NO_2 (X_4) dengan PM 2,5 (Y) sebagai target. Jumlah *neuron* dan *hidden layer* ditentukan berdasarkan *rule of thumb*. Di mana, jumlah *hidden layer* yang disarankan adalah sebanyak 2 *layer* maka dalam penelitian ini *hidden layer* yang digunakan sebanyak 2 *hidden layer*. Untuk jumlah *neuron* pada *hidden layer* harus setidaknya lebih besar dari dua kali banyaknya input, maka total *neuron hidden layer* yang digunakan sebanyak 8 *neuron* (5 *neuron* di hidden *layer* pertama dan 3 *neuron* di *hidden layer* kedua).

Penentuan Nilai *Learning Rate*

Untuk nilai *learning rate* ditentukan berdasarkan perbandungan nilai MAPE terkecil dengan nilai *learning rate* ialah 0,0005; 0,0001; 0,00005.

Tabel 1. Nilai Learning Rate berdasarkan Nilai MAPE

Nilai *Learning Rate*	Nilai MAPE
0,0005	11,14132
0,0001	11,14114
0,00005	11,14111

Berdasarkan nilai MAPE pada Tabel 5, maka nilai *learning rate* yang digunakan ialah sebesar 0,00005.

Proses *Backpropagation*

Fungsi aktivasi yang digunakan dalam *hidden layer* adalah logistik sigmoid dan fungsi aktivasi dalam *output layer* adalah linear. Berdasarkan penentuan tersebut, maka berikut proses untuk mendapatkan nilai prediksi:

Tabel 2. Nilai Bobot Akhir Layer 1

$w_{i,k}^{(1)}$	1	2	3	4	5

1	-0,6045	1,6007	0,8440	1,7721	-1,0971
2	-0,2186	0,2698	-0,1041	0,6472	-0,2206
3	1,5323	-1,3006	0,3228	-1,9589	-1,0411
4	0,0681	-0,6539	0,1575	0,6318	-0,7400
5	0,1506	-0,8067	-1,5281	-0,2120	-0,6197

Tabel tersebut merupakan tabel bobot untuk *hidden layer* pertama berdasarkan algoritma *backpropagation* dengan inisialisasi bobot secara *random*. Setelah bobot pada *hidden layer* pertama didapatkan, maka dapat dilanjutkan dengan jumlah terboboti dengan perhitungan seperti berikut dengan *i* sebagai pengamatan ke-*i*:

$$z_{i1}^{(1)} = -0.6045 + \left(-0.2186 \times a_{i1}^{(0)}\right) + \left(1.5323 \times a_{i2}^{(0)}\right) + \left(0.0681 \times a_{i3}^{(0)}\right) + \left(0.1506 \times a_{i4}^{(0)}\right)$$

$$\vdots$$

$$z_{i5}^{(1)} = -1.0971 + \left(-0.2206 \times a_{i1}^{(0)}\right) + \left(-1.0411 \times a_{i2}^{(0)}\right) + \left(-0.7400 \times a_{i3}^{(0)}\right) + \left(-0.6197 \times a_{i4}^{(0)}\right)$$

Hasil dari jumlah terboboti ini kemudian dimasukkan ke dalam fungsi aktivasi, sehingga diperoleh output untuk *hidden layer* pertama ($\varphi(z^{(1)})$) melalui perhitungan berikut dengan *i* sebagai pengamatan ke-*i*:

$$a_{i1}^{(1)} = \left[a_{i1}^{(1)}\right] = \varphi\left(z_{i1}^{(1)}\right) = \left[\frac{1}{1 + \exp\left(-z_{i1}^{(1)}\right)}\right]$$

$$\vdots$$

$$a_{i5}^{(1)} = \left[a_{i5}^{(1)}\right] = \varphi\left(z_{i5}^{(1)}\right) = \left[\frac{1}{1 + \exp\left(-z_{i5}^{(1)}\right)}\right]$$

Output ini selanjutnya menjadi *input* bagi *hidden layer* kedua $(a^{(1)})$, di mana setiap *neuron* pada *hidden layer* kedua dikalikan dengan bobotnya masing-masing ($W^{(2)}$) dan ditambahkan bias ($a_0^{(1)}$). Bobot untuk *hidden layer* kedua dapat dilihat pada tabel berikut:

Tabel 3. Nilai Bobot Akhir Layer 2

$w_{i,k}^{(2)}$	1	2	3
1	-1,5872	-0,6125	-0,0904
2	0,8381	0,7736	-0,3141
3	0,1381	0,7336	-0,3655
4	-1,4740	1,0141	-0,6258
5	1,2700	0,5261	-0,2160
6	0,3130	0,6369	-1,2328

Perkalian *input* dari *hidden layer* kedua $(a^{(1)})$ dengan bobot masing-masing *neuron* ($W^{(2)}$), ditambah dengan bias ($a_0^{(1)}$), menghasilkan jumlah terboboti untuk *hidden layer* kedua ($z^{(2)}$) dengan perhitungan seperti berikut dengan *i* sebagai pengamatan ke-*i*:

$$z_{i1}^{(2)} = -1{,}5872 + \left(0{,}8381 \times a_{i1}^{(1)}\right) + \left(0{,}1381 \times a_{i2}^{(1)}\right) + \left(-1{,}4740 \times a_{i3}^{(1)}\right) + \left(1{,}27 \times a_{i4}^{(1)}\right) + \left(0{,}313 \times a_{i5}^{(1)}\right)$$

$$\vdots$$

$$z_{i3}^{(2)} = -0{,}0904 + \left(-0{,}3141 \times a_{i1}^{(1)}\right) + \left(-0{,}3655 \times a_{i2}^{(1)}\right) + \left(-0{,}6258 \times a_{i3}^{(1)}\right) + \left(-0{,}216 \times a_{i4}^{(1)}\right) + \left(-1{,}2328 \times a_{i4}^{(1)}\right)$$

Nilai ini kemudian dimasukkan ke dalam fungsi aktivasi sehingga diperoleh *output* dari *hidden layer* kedua ($\varphi(z^{(2)})$) melalui perhitungan berikut dengan *i* sebagai pengamatan ke-*i*:

$$a_{i1}^{(2)} = \left[a_{i1}^{(2)}\right] = \varphi\left(z_{i1}^{(2)}\right) = \left[\frac{1}{1 + \exp\left(-z_{i1}^{(2)}\right)}\right]$$

$$\vdots$$

$$a_{i3}^{(2)} = \left[a_{i3}^{(2)}\right] = \varphi\left(z_{i3}^{(2)}\right) = \left[\frac{1}{1 + \exp\left(-z_{i3}^{(2)}\right)}\right]$$

Output ini selanjutnya digunakan sebagai *input* $(a^{(2)})$ untuk *output layer*, di mana setiap nilai $(a^{(2)})$ dikalikan dengan bobot ($W^{(3)}$) dan ditambahkan bias ($a_0^{(2)}$) untuk menghasilkan prediksi akhir ($\varphi(z^{(3)})$). Bobot yang digunakan untuk memperoleh output dapat dilihat pada tabel berikut:

Tabel 4. Nilai Bobot Akhir Layer 3

$w_{i,k}^{(3)}$	1
1	1,6707
2	1,3881
3	-1,9024
4	-0,1291

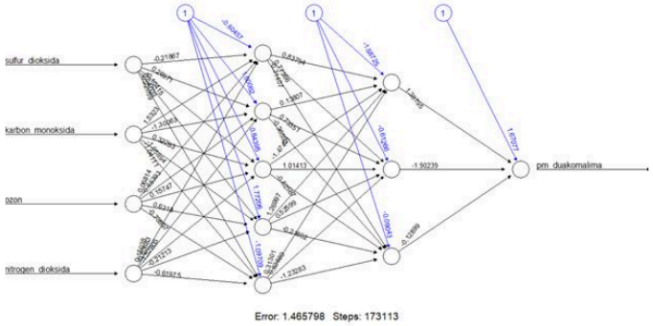
Perkalian *input* dari *hidden layer* kedua $(a^{(2)})$ dengan bobot masing-masing *neuron* ($W^{(3)}$), ditambah dengan bias ($a_0^{(3)}$), menghasilkan jumlah terboboti untuk *hidden layer* kedua ($z^{(3)}$) dengan perhitungan seperti berikut dengan *i* sebagai pengamatan ke-*i*:

$$z_{i1}^{(3)} = 1{,}6707 + \left(1{,}3881 \times a_{i1}^{(2)}\right) + \left(-1{,}9024 \times a_{i2}^{(2)}\right) + \left(-0{,}1291 \times a_{i3}^{(2)}\right)$$

Nilai dari hasil tersebut, kemudian dimasukkan ke dalam fungsi aktivasi sehingga diperoleh *output* dari *hidden layer* kedua ($\varphi(z^{(3)})$) melalui perhitungan berikut dengan *i* sebagai pengamatan ke-*i*:

$$a_{i1}^{(3)} = \left[a_{i1}^{(3)}\right] = \varphi\left(z_{i1}^{(3)}\right) = \left[\frac{1}{1 + \exp\left(-z_{i1}^{(3)}\right)}\right]$$

Untuk Gambaran lebih lengkapnya dapat dilihat pada gambar berikut:



Gambar 2. Arsitektur ANN

Hasil *output* ini dilanjutkan dengan denormalisasi agar hasil *output* kembali ke hasil aslinya untuk membandingkan antara data aktual dengan hasil prediksi.

Evaluasi Model ANN

Menghitung nilai MAPE dilakukan dengan menggunakan data *testing* yang telah disesuaikan melalui pembagian data yang dilakukan sebelumnya yaitu 20% dari data atau sebanyak 43 data. Nilai MAPE berasal dari nilai data aktual dan data prediksi yang dihitung menggunakan persamaan (3),(4), dan (5). Didapat dari proses ANN *Backpropagation* seperti Tabel 1 berikut.

Tabel 5. Nilai Hasil Perhitungan MAPE

Simulasi	MAPE	MSE	R^2
Training	9,4522737	112,4808	0,1689
Testing	11,14132	124,4607	0,2609

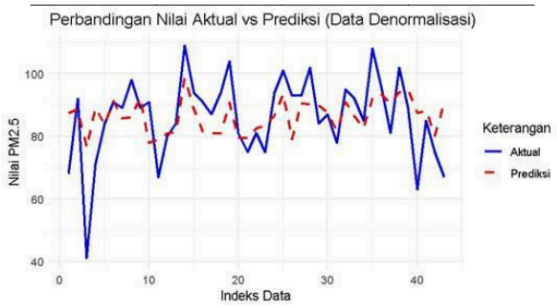
Hasil evaluasi model ANN menunjukkan nilai MSE sebesar 124,46 dan MAPE 11,14%, yang menandakan model mampu menangkap pola data dengan baik meskipun beberapa baris mengalami kesulitan prediksi. Nilai MAPE pada data training lebih rendah dibanding data testing, sedangkan R^2 pada data testing lebih tinggi, menunjukkan model mampu menjelaskan 16–26% variasi data target. Hasil ini mengindikasikan bahwa model masih memiliki ruang perbaikan dalam menangkap hubungan antara variabel *input* dan *output*.

Hasil Prediksi

Setelah melalui proses pelatihan dan di lakukan pengujian pada data *testing* dan *training*, dihasilkan hasil prediksi secara keseluruh. Nilai hasil prediksi akan dibandingkan dengan nilai aktual untuk mengetahui akurasi dari model ANN. Hasil prediksi secara lengkap disajikan dalam tabel dan gambar berikut:

Tabel 6. Nilai Aktual vs Prediksi Data Testing

No	Aktual	Prediksi	Selisih
1	68	87.48	19.48
2	92	88.48	3.52
3	41	76.39	35.39
:	:	:	:
:	:	:	:
41	85	88.34	3.34
42	75	80.22	5.22
43	67	90.69	23.69



Gambar 3. Nilai Aktual vs Prediksi Data Testing

Secara keseluruhan, model tersebut dapat mengikuti pola pergerakan dari data kualitas udara di Bundaran HI DKI Jakarta, meskipun terdapat terdapat beberapa titik nilai prediksi dimana berbeda dengan nilai aktual. Hal tersebut menunjukkan bahwa model masih cukup akurat, meski terdapat sedikit perbedaan.

4. KESIMPULAN

Berdasarkan hasil penelitian, model *Artificial Neural Network* (ANN) dengan algoritma *Backpropagation* berhasil dibangun untuk memprediksi konsentrasi PM2.5 harian di DKI Jakarta tahun 2023 menggunakan variabel SO_2, CO, O_3, dan NO_2. Setelah melalui tahap preprocessing, normalisasi, pembagian data, serta penentuan arsitektur jaringan 4-5-3-1 dengan learning rate terbaik sebesar 0.00005, model menghasilkan nilai MAPE sebesar 11,14% pada data *testing*. Nilai tersebut menunjukkan bahwa model cukup mampu mengikuti pola perubahan PM2.5, meskipun belum mencapai tingkat akurasi yang sangat baik (MAPE < 10%). Secara keseluruhan, model ANN ini dapat digunakan sebagai pendekatan awal untuk memprediksi kualitas udara, namun performanya masih dapat ditingkatkan melalui optimasi arsitektur dan penambahan variabel yang lebih relevan.

UCAPAN TERIMA KASIH

Penulis menyampaikan rasa terima kasih yang sebesar-besarnya kepada Bapak Suliadi, S.Si., M.Si., Ph.D., selaku dosen pengampu mata kuliah *Machine Learning*, atas bimbingan, arahan, serta dukungan ilmiah yang sangat berharga dalam proses penyusunan artikel ini. Nasihat dan pengetahuan yang beliau berikan telah membantu penulis dalam memahami konsep, metode, serta analisis yang digunakan dalam penelitian ini.

DAFTAR PUSTAKA

[1] Dinas Lingkungan Hidup Provinsi DKI Jakarta, "Kajian Pemantauan Kualitas Udara di Provinsi DKI Jakarta," 2023, Accessed: Nov. 15, 2025. [Online]. Available: https://dev.dinaslhdki.id/uploads/images/galery/udara-2023-la_20250702130132.pdf

[2] IQAir, "World's Most Polluted Cities 2023 (PM2.5 concentration)," 2023, Accessed: Nov. 15, 2025. [Online]. Available: https://www.iqair.com/world-most-polluted-cities

[3] World Health Organization, "WHO global air quality guidelines: Particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide," 2021, Accessed: Nov. 15, 2025. [Online]. Available: https://www.who.int/publications/i/item/9789240034228

[4] G. Ayu, N. Lestari, N. Dwi, and A. Mahendra, "Prediksi Kualitas Udara dengan Menggunakan Metode Long Short-Term Memory dan Artificial Neural Network," 2023, Accessed: Nov. 15, 2025. [Online]. Available: https://jsi.stikom-bali.ac.id/index.php/jsi/article/view/565/243

[5] A. Rivero-Cacho, G. Sánchez-Barroso, P. Pastor-Pérez, and J. García-Sanz-Calcedo, "Forecasting indoor air quality in high-risk operating theatres in hospitals using

Artificial Neural Networks," *Journal of Building Engineering*, vol. 111, Oct. 2025, doi: 10.1016/j.jobe.2025.113339.

[6] N. Hikmah, S. Bahri, and I. Irwansyah, "Jaringan Syaraf Tiruan untuk Memprediksi Kadar Polutan Ozon di Kota Mataram," *EIGEN MATHEMATICS JOURNAL*, pp. 70–85, Dec. 2022, doi: 10.29303/emj.v5i2.129.

[7] I. N. K. Wardana, J. W. Gardner, and S. A. Fahmy, "Optimising deep learning at the edge for accurate hourly air quality prediction," *Sensors (Switzerland)*, vol. 21, no. 4, pp. 1–28, Feb. 2021, doi: 10.3390/s21041064.

[8] S. A. Alasadi and W. S. Bhaya, "Review of data preprocessing techniques in data mining," *Journal of Engineering and Applied Sciences*, vol. 12, no. 16, pp. 4102–4107, Sep. 2017, doi: 10.3923/jeasci.2017.4102.4107.

[9] S. Aswatha *et al.*, "Smart air pollution monitoring system," *Global Nest Journal*, vol. 25, no. 3, pp. 125–129, Mar. 2023, doi: 10.30955/gnj.004396.

[10] K. Kumar and B. P. Pande, "Air pollution prediction with machine learning: a case study of Indian cities," *International Journal of Environmental Science and Technology*, vol. 20, no. 5, pp. 5333–5348, May 2023, doi: 10.1007/s13762-022-04241-5.

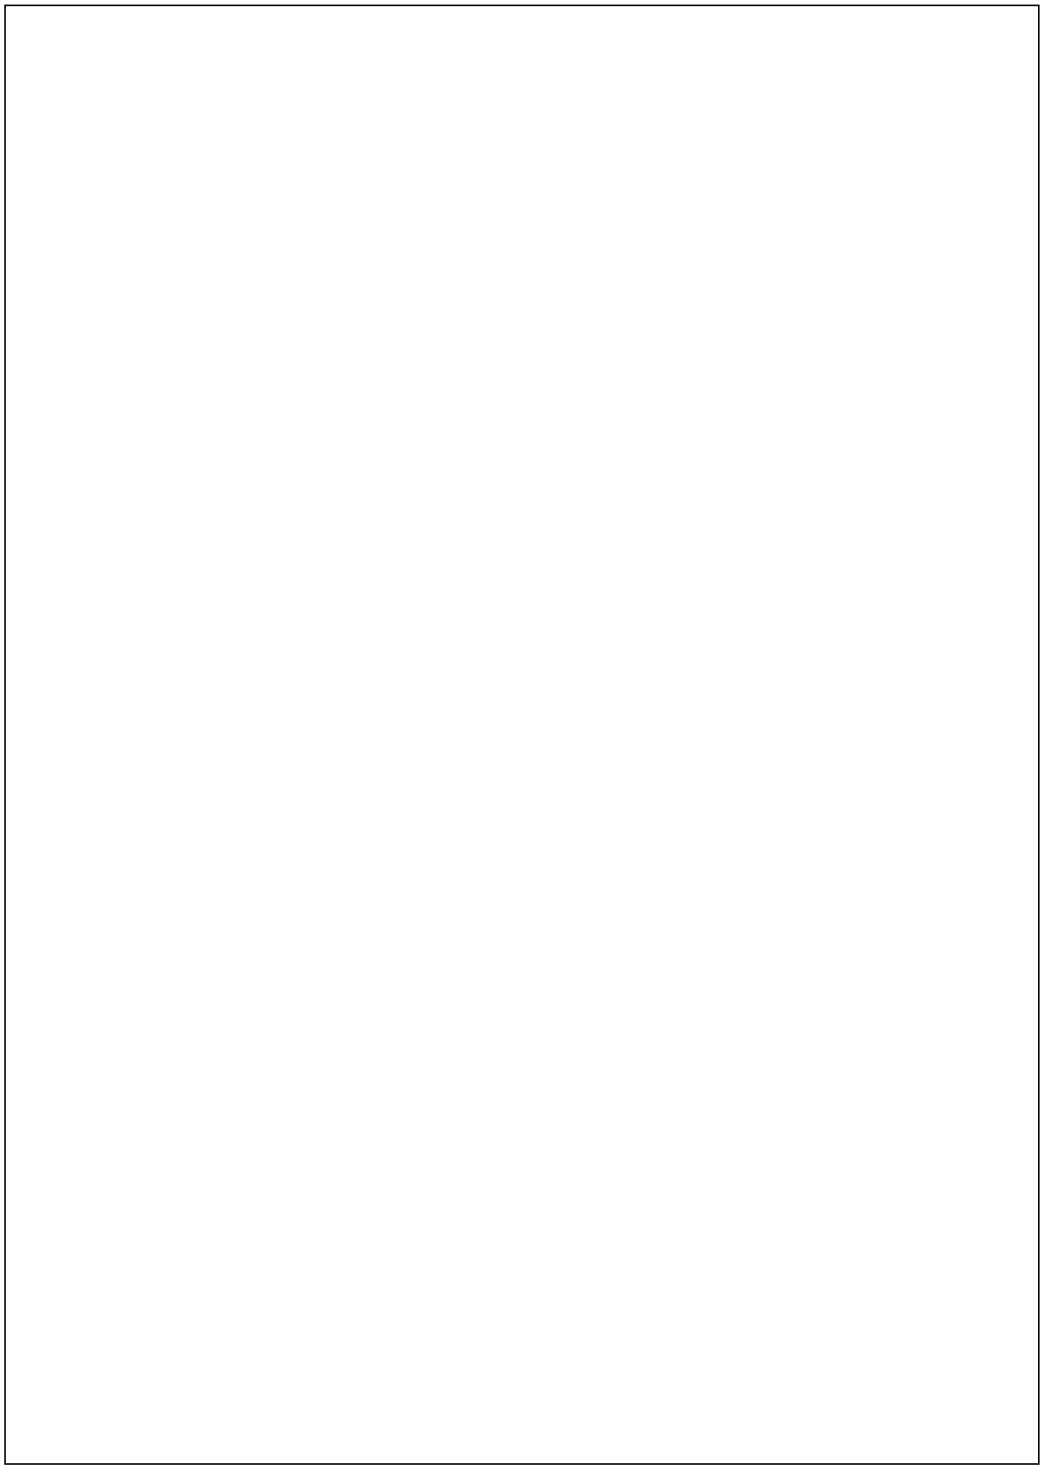
[11] K. Alrasheed, M. Al Ballat, E. Soliman, and H. Albader, "Artificial Neural Network-based cost estimation for public construction projects in Kuwait," *Journal of Engineering Research*, Sep. 2025, doi: 10.1016/j.jer.2025.09.001.

[12] H. I. Hussein *et al.*, "Design of artificial neural networks for darcy-forchheimer flow of boger hybrid nanofluid with CattaneoChristov theory: Thermofluidic applications," *International Journal of Thermofluids*, vol. 30, p. 101473, Nov. 2025, doi: 10.1016/j.ijft.2025.101473.

[13] I. N. T. Adnyana, I. G. P. S. Wijaya, and M. A. Albar, "Jaringan Syaraf Tiruan Model Backpropagation untuk Peramalan Suhu Minimum dan Maksimum, Kelembaban, Tekanan Udara, Jumlah Hari Hujan, dan Curah Hujan Bulanan di Kota Mataram," *Journal of Computer Science and Informatics Engineering (J-Cosine)*, vol. 3, no. 2, Dec. 2019, doi: 10.29303/jcosine.v3i2.259.

[14] S. Maslamah, Aripriharta, A. N. Handayani, G.-J. Horng, and M. cahyo Bagaskoro, "Forecasting New State University Student Admissions Through The XII Level Student Achievement Pathway Smk Negeri 1 Bandung Tulungagung Using Arima Method," *Journal of Education Technology*, vol. 9, no. 1, Apr. 2025, doi: 10.23887/jet.v9i1.86015.

[15] Y. Hendra, H. Mukhtar, and R. Hafsari, "PREDIKSI CURAH HUJAN DI KOTA PEKANBARU MENGGUNAKAN LSTM (LONG SHORT TERM MEMORY)," 2023.



UTS_Machine Learning_Kel 6

ORIGINALITY REPORT

19%	17%	9%	6%
SIMILARITY INDEX	INTERNET SOURCES	PUBLICATIONS	STUDENT PAPERS

PRIMARY SOURCES

1	repository.its.ac.id Internet Source	2%
2	etheses.uin-malang.ac.id Internet Source	1%
3	www.researchgate.net Internet Source	1%
4	repository.ub.ac.id Internet Source	1%
5	www.scribd.com Internet Source	1%
6	jurnal.ranahresearch.com Internet Source	1%
7	Intania Dharma Hartarti, Intan Amelia Septiyani, Daniel Armando Gultom, Yayan Hendrian, Shynde Limar Kinanti. "Prediksi Harga Rumah di Boston Dengan Model Regresi Linear Menggunakan Python", RIGGS: Journal of Artificial Intelligence and Digital Business, 2025 Publication	1%
8	jutif.if.unsoed.ac.id Internet Source	1%
9	www.coursehero.com Internet Source	1%
10	Alrafiful Rahman, Valentinus Paramarta, Agnes Novita Ida, Mohammad Harits Akbar,	1%

	Vica Sonya M Simanjuntak. "Perbandingan Kinerja SVR dan XGBoost untuk Peramalan Emisi CO_2 Global berbasis Machine Learning", Jurnal Komtika (Komputasi dan Informatika), 2025 Publication	
11	iontech.ista.ac.id Internet Source	1 %
12	data-science-blog.com Internet Source	<1 %
13	journals.sagepub.com Internet Source	<1 %
14	journals.unisba.ac.id Internet Source	<1 %
15	Submitted to Sultan Agung Islamic University Student Paper	<1 %
16	Submitted to Tilburg University Student Paper	<1 %
17	Submitted to Universitas Diponegoro Student Paper	<1 %
18	repositori.uma.ac.id Internet Source	<1 %
19	Submitted to Universitas Brawijaya Student Paper	<1 %
20	e-journal.hamzanwadi.ac.id Internet Source	<1 %
21	proceedings.unisba.ac.id Internet Source	<1 %
22	digilib.unila.ac.id Internet Source	<1 %
23	konsultasiskripsi.com	

	Internet Source	<1%
24	Putri Pratiwi, Dima Dwifa, Anita Desiani, Ali Amran, Bambang Suprihatin. "Klasifikasi Penyakit Kanker Paru-Paru Menggunakan Algoritma Naïve Bayes dan Iterative Dichotomizer 3 (ID3)", Electrician : Jurnal Rekayasa dan Teknologi Elektro, 2024 Publication	<1%
25	Submitted to Universitas Bengkulu Student Paper	<1%
26	repository.unhas.ac.id Internet Source	<1%
27	rumahpengetahuan.web.id Internet Source	<1%
28	sawitwatch.or.id Internet Source	<1%
29	Sudirman S. Panna, Aprianto Alhamad, Kartika Chandra Pelangi. "Pengenalan Ekspresi Wajah Pengemudi Berbasis Fitur Eigenface dan Gray Level Co-Occurance Matrice", Jurnal Edukasi dan Penelitian Informatika (JEPIN), 2023 Publication	<1%
30	ejurnal.itats.ac.id Internet Source	<1%
31	eprints2.undip.ac.id Internet Source	<1%
32	jurnal.stts.edu Internet Source	<1%
33	library.binus.ac.id Internet Source	<1%

34	text-id.123dok.com Internet Source	<1%
35	tribowo17-nine-wee.blogspot.com Internet Source	<1%
36	www.ijraset.com Internet Source	<1%
37	Muhammad Miftakhudin, Aang Alim Murtopo, Zaenul Arif. "Integrasi Artificial Neural Network dan Algoritma Genetika untuk Prediksi Bencana Banjir Pesisir Kota Tegal", RIGGS: Journal of Artificial Intelligence and Digital Business, 2025 Publication	<1%
38	kimia.fmipa.unesa.ac.id Internet Source	<1%

Exclude quotes	Off	Exclude matches	Off
Exclude bibliography	On		